TCGA Pan-Kanser RNA-Seq Verileri Kullanılarak Kanser Türlerinin Makine Öğrenimi Tabanlı Çok Sınıflı Sınıflandırılması

SÜMEYYE BAKIRDAL

Fırat Üniversitesi, Mühendislik Fakültesi, Bilgisayar Mühendisliği Bölümü,Elazığ
sumeyyebakirdal@gmail.com

Özet

Günümüzde yüksek boyutlu biyolojik verilerin analizi, kanserin erken tanısı ve tedavi planlarının oluşturulmasında önemli katkılar sağlamaktadır. Bu çalışmada, TCGA Pan-Kanser RNA-Seq verileri kullanılarak farklı kanser türlerinin çok sınıflı makine öğrenimi tabanlı sınıflandırılması gerçekleştirilmiştir. Veri ön işleme aşamasında, gen ekspresyon verileri normalize edilmiş ve yüksek varyanslı genler ile anlamlı özellikler seçilmiştir. Boyut indirgeme amacıyla PCA uygulanarak kanser türleri arasındaki dağılım görselleştirilmiştir. Ardından, sınıflandırma performansını değerlendirmek üzere dört farklı makine öğrenimi algoritması (Lojistik Regresyon, Rastgele Orman, Destek Vektör Makineleri ve Yapay Sinir Ağları) karşılaştırılmıştır. Modeller 5 katlı çapraz doğrulama ile test edilmiş, sonuçlar doğrultusunda lojistik regresyon modeli en yüksek doğruluk oranına (%94.6) ulaşarak en başarılı sınıflandırıcı olarak belirlenmiştir. Elde edilen bulgular, RNA-Seq verilerinden seçilen genlerin kanser türlerinin etkili bir şekilde ayrımında kullanılabileceğini göstermekte olup, biyomedikal veri analizinde makine öğrenimi yaklaşımlarının güçlü bir araç olduğunu ortaya koymaktadır. Gelecekte, model karmaşıklığının artırılması ve diğer omik veri tipleri ile entegrasyonun, sınıflandırma başarısını daha da iyileştirebileceği düşünülmektedir.

Anahtar Kelimeler: TCGA, Pan-Kanser, RNA-Seq, çok sınıflı sınıflandırma, makine öğrenmesi, lojistik regresyon, gen ifadesi, özellik seçimi, temel bileşen analizi, kanser türleri.

Abstract

Analysis of high-dimensional biological data plays an important role in early cancer diagnosis and the development of treatment plans today. In this study, multi-class classification of various cancer types was performed using TCGA Pan-Cancer RNA-Seq data through machine learning approaches. During data preprocessing, gene expression profiles were normalized, and high-variance genes alongside statistically significant features were selected. Principal Component Analysis (PCA) was applied to visualize the distribution of cancer types in reduced dimensional space. Subsequently, four different machine learning algorithms—Logistic Regression, Random Forest, Support Vector Machines, and Neural Networks—were compared in terms of classification performance. Models were evaluated using 5-fold cross-validation, and Logistic Regression achieved the highest accuracy (94.6%), emerging as the most effective classifier. These findings indicate that selected genes from RNA-Seq data can successfully discriminate cancer types, demonstrating the robustness of machine learning techniques in biomedical data analysis. Future work may focus on increasing model complexity and integrating additional omics data to further enhance classification performance.

Keywords: TCGA, Pan-Cancer, RNA-Seq, multi-class classification, machine learning, logistic regression, gene expression, feature selection, principal component analysis, cancer types.

1. Giriş

Kanser, hücresel düzeyde meydana gelen genetik ve epigenetik değişimlerin yol açtığı kontrolsüz hücre bölünmesiyle karakterize edilen karmaşık ve heterojen bir hastalık grubudur. Dünya genelinde yüksek morbidite ve mortalite oranları nedeniyle, erken ve doğru tanı yöntemlerinin geliştirilmesi sağlık sistemleri için büyük önem taşımaktadır. Son yıllarda biyoteknolojide yaşanan gelişmeler sayesinde, özellikle hücresel genetik aktiviteleri inceleme imkanı sunan RNA dizileme (RNA-Seq) teknolojisi, kanser biyolojisinin anlaşılmasında devrim niteliğinde ilerlemeler sağlamıştır.

RNA-Seq teknolojisi, belirli bir hücre ya da dokuda yer alan genlerin ekspresyon seviyelerini nicel olarak ölçebilen yüksek verimli bir dizileme yöntemidir. Bu sayede farklı kanser türleri arasındaki gen ifade farklılıkları daha net şekilde ortaya konulabilmekte; biyobelirteç keşfi, hastalık alt türlerinin belirlenmesi ve tanısal modellerin geliştirilmesi açısından önemli fırsatlar sunulmaktadır. Ancak, RNA-Seq verilerinin binlerce gen içeren yüksek boyutlu yapısı ve bazı kanser türlerinde örnek sayısının sınırlı olması, klasik istatistiksel yöntemler açısından analiz süreçlerini zorlaştırmaktadır. Bu noktada, makine öğrenmesi (ML) algoritmaları özellikle çoklu sınıflandırma problemlerinde etkili çözümler sunarak ön plana çıkmaktadır.

Bu çalışmada, The Cancer Genome Atlas (TCGA) projesi kapsamında toplanan Pan-Cancer RNA-Seq verisi kullanılarak farklı kanser türlerinin sınıflandırılması amaçlanmıştır. Çalışmanın temel hedefi, gen ekspresyon verisi üzerinden farklı makine öğrenimi algoritmalarını karşılaştırmak ve en yüksek sınıflandırma başarımını elde eden modeli belirlemektir. Ayrıca modelin karar mekanizmasına katkıda bulunan en önemli genlerin belirlenmesiyle potansiyel biyobelirteç adayları da ortaya konulmuştur.

Bu çalışma, hem biyomedikal veri bilimi literatürüne katkı sağlamayı hem de RNA-Seq tabanlı tanısal modellerin geliştirilmesine yönelik çalışmalara altyapı oluşturmayı amaçlamaktadır. Ayrıca, farklı kanser türlerine özgü gen ifade desenlerinin belirlenmesine yönelik yapılan bu analizlerin, gelecekte klinik karar destek sistemlerinin geliştirilmesinde de önemli bir potansiyele sahip olduğu düşünülmektedir.

2. Literatür Taraması

Kanser, dünya genelinde en önemli sağlık sorunlarından biri olup, hastalığın doğru ve erken tanısı, tedavi stratejilerinin belirlenmesi ve hastaların yaşam kalitesinin artırılması açısından kritik bir öneme sahiptir (Siegel et al., 2020). Geleneksel tanı yöntemleri histopatolojik incelemelerle sınırlı kalmakta, bu da kanser türlerinin moleküler farklılıklarını tam anlamıyla ortaya koyamamaktadır. Bu noktada, moleküler biyoloji ve genomik alanındaki gelişmeler, özellikle yüksek verimli RNA dizileme (RNA-Seq) teknolojileri, kanser biyolojisinin daha iyi anlaşılması ve sınıflandırılması için yeni olanaklar sağlamıştır (Wang et al., 2009).

The Cancer Genome Atlas (TCGA) projesi, farklı kanser türlerine ait geniş çaplı genomik, epigenomik ve transkriptomik verileri toplayarak kanser araştırmalarında çığır açmıştır (Weinstein et al., 2013). TCGA'nın sunduğu RNA-Seq verileri, kanser hücrelerinin gen ekspresyon profillerini yüksek çözünürlükte ortaya koymakta, bu da kanser türlerinin moleküler düzeyde sınıflandırılmasını mümkün kılmaktadır. Böylelikle, klinik tanı ve tedavi kararlarında kişiselleştirilmiş tıp uygulamalarının yolu açılmıştır.

Makine öğrenimi (ML) teknikleri, biyomedikal veri analizinde karmaşıklığı yönetebilme ve yüksek boyutlu verilerden anlamlı desenler çıkarabilme yetenekleri nedeniyle popülerlik kazanmıştır (Libbrecht ve Noble, 2015). Kanser türlerinin sınıflandırılması bağlamında, ML algoritmaları kanser hücrelerinin moleküler imzalarını belirleyerek sınıflandırma doğruluğunu önemli ölçüde artırmaktadır (Kourou et al., 2015). Özellikle lojistik regresyon, destek vektör makineleri (SVM), rastgele orman (Random Forest), ve yapay sinir ağları (ANN) gibi algoritmalar, farklı çalışmalar kapsamında performansları ile dikkat çekmiştir (Zhang ve Zhou, 2020).

Biyomedikal veriler genellikle yüksek boyutlu ve gürültü içermesi nedeniyle doğrudan ML modellerine uygulanması zordur. Bu nedenle, veri ön işleme ve özellik seçimi aşamaları, model başarısı için kritik önem taşır. Özellik seçimi teknikleri arasında varyans tabanlı filtreler, istatistiksel testlere dayanan yöntemler (ANOVA, SelectKBest) ve boyut indirgeme yöntemleri (Principal Component Analysis - PCA) yaygın olarak kullanılmaktadır (Guyon ve Elisseeff, 2003; Chandrashekar ve Sahin, 2014). Bu teknikler, gereksiz ve gürültülü genleri elimine ederek, modelin aşırı öğrenmesini (overfitting) önlemekte ve genelleme yeteneğini artırmaktadır.

TCGA Pan-Cancer verisi kullanılarak yapılan çok sayıda çalışma, RNA-Seq tabanlı gen ekspresyon profilleri ile kanser türlerinin çok sınıflı sınıflandırılmasında yüksek doğruluk elde edildiğini göstermiştir. Liu ve ark. (2020) çalışmasında, lojistik regresyon ve rastgele orman modelleri ile %94'ün üzerinde doğruluk oranları bildirilmiştir. Benzer şekilde, Li ve ark. (2019), farklı kanser türlerini ayırt etmek için TCGA RNA-Seq verisini kullanarak derin öğrenme ve klasik ML yöntemlerini karşılaştırmış, her iki yaklaşımın da yüksek performans sergilediğini ortaya koymuştur. Ayrıca, derin öğrenme modellerinin büyük veri setlerinde daha karmaşık örüntüleri öğrenme kapasitesi nedeniyle avantaj sağlayabileceği belirtilmiştir.

Makine öğrenimi modellerinin klinik uygulamalara entegrasyonu açısından, model açıklanabilirliği (interpretability) büyük önem taşımaktadır. Rastgele orman gibi ağaç tabanlı modeller, değişken önem düzeylerini (feature importance) doğrudan sunabilmesiyle tercih edilmektedir (Chen ve Guestrin, 2016). Öte yandan, lojistik regresyon modelleri katsayıları sayesinde hangi genlerin sınıflandırmada daha etkili olduğunu analiz etmeye olanak tanır. Bu biyolojik anlamlılık, moleküler hedeflerin belirlenmesi ve tedavi stratejilerinin geliştirilmesi için kritik bir bilgi kaynağıdır.

Son yıllarda, çoklu omik veri entegrasyonu (genomik, transkriptomik, proteomik vb.) ve derin öğrenme tabanlı yöntemlerin kanser sınıflandırmasında yeni ufuklar açtığı görülmektedir (Chaudhary et al., 2018). Ancak, bu yaklaşımlar yüksek hesaplama gücü ve büyük veri gereksinimleri nedeniyle hala geliştirilme aşamasındadır. Buna karşılık, klasik makine öğrenimi algoritmaları hem hesaplama verimliliği hem de yorumlanabilirlik açısından halen tercih edilmektedir.

Özetle, TCGA Pan-Cancer RNA-Seq verileri ve makine öğrenimi algoritmaları, kanser türlerinin çok sınıflı sınıflandırılmasında güçlü bir temel sağlamaktadır. Bu çalışmalar, moleküler düzeyde kişiselleştirilmiş tanı ve tedavi stratejilerinin geliştirilmesine katkıda bulunmakta, kanser biyolojisinin anlaşılmasına ışık tutmaktadır. Gelecek araştırmaların, çoklu omik veri entegrasyonu, gelişmiş model açıklanabilirliği ve klinik doğrulama süreçlerine odaklanarak bu alandaki bilgi birikimini daha da derinleştirmesi beklenmektedir.

3. Yöntem

3.1. Veri Seti

Bu çalışmada The Cancer Genome Atlas (TCGA) konsorsiyumu tarafından sağlanan Pan-Cancer RNA-Seq verileri kullanılmıştır. RNA-Seq ifade verileri ve hasta bilgilerini içeren klinik metadata iki ayrı kaynak olarak indirilmiştir. RNA-Seq veri seti, 20.533 gen için toplam 10.230 örnekten oluşmaktadır. Klinik metadata ise her örneğin kanser tipini ve örnek kimliğini içermektedir.

3.2. Veri Temizleme ve Birleştirme

İlk adım olarak, gen ekspresyon veri setindeki örnek isimleri (barcode) TCGA'nın standart 12 karakterlik örnek ID formatına dönüştürüldü. Bu sayede gen ekspresyon verisi ile klinik metadata üzerinde uyumlu birleştirme işlemi gerçekleştirildi. Yinelenen (duplicate) örnekler elenerek birleşik bir veri seti oluşturuldu.

Bu işlemlerin sonucunda, analiz için kullanılabilir hale getirilen birleşik veri seti 10.230 örnek ve 20.533 özellik (gen) içermekteydi. Ancak ham veri üzerinde oldukça fazla eksik değer mevcuttu; toplamda yaklaşık 3.801.991 eksik veri noktası tespit edildi. Eksik verilerin analiz sonuçlarını olumsuz etkilememesi için uygun imputation (tamamlama) yöntemleri uygulandı.

3.3. Özellik Seçimi ve Boyut İndirgeme

RNA-Seq verisinin yüksek boyutluluğu (20 binden fazla gen) nedeniyle, modelleme öncesi veri boyutunu azaltmak amacıyla çok aşamalı bir özellik seçimi süreci gerçekleştirildi:

Varyans Eşikleme (Variance Threshold): İlk aşamada varyansı çok düşük olan genler, modele anlamlı katkı sağlamayacağı varsayımıyla elendi. Bu işlem sonucunda özellik sayısı 20.311'e indirildi.

İstatistiksel Özellik Seçimi (SelectKBest): İkinci aşamada, istatistiksel olarak sınıflandırma problemini en iyi ayırt eden genler seçildi. Bu yöntemde her genin hedef değişkenle olan ilişkisine göre skoru hesaplanarak en yüksek skora sahip 500 gen analize dahil edildi. Böylece son modelleme aşamasında kullanılacak özellik sayısı önemli ölçüde azaltılmış oldu.

Bu iki aşamalı seçim, hem modelin hesaplama yükünü azalttı hem de aşırı öğrenme (overfitting) riskini minimize etti.

```
Birleşik veri şekli: (10230, 20533)
Toplam eksik veri: 3801991
Varyans seçimi sonrası boyut: (8560, 20311)
SelectKBest sonrası boyut: (8560, 500)
```

Şekil 1. Veri setlerinin birleştirilmesi ve boyut indirgeme işlemleri sonrası örnek ve özellik sayılarındaki değişim. Başlangıçta 20.533 gen içeren veri seti, varyans analizi ve SelectKBest yöntemiyle 500 özelliğe indirgenmiştir.

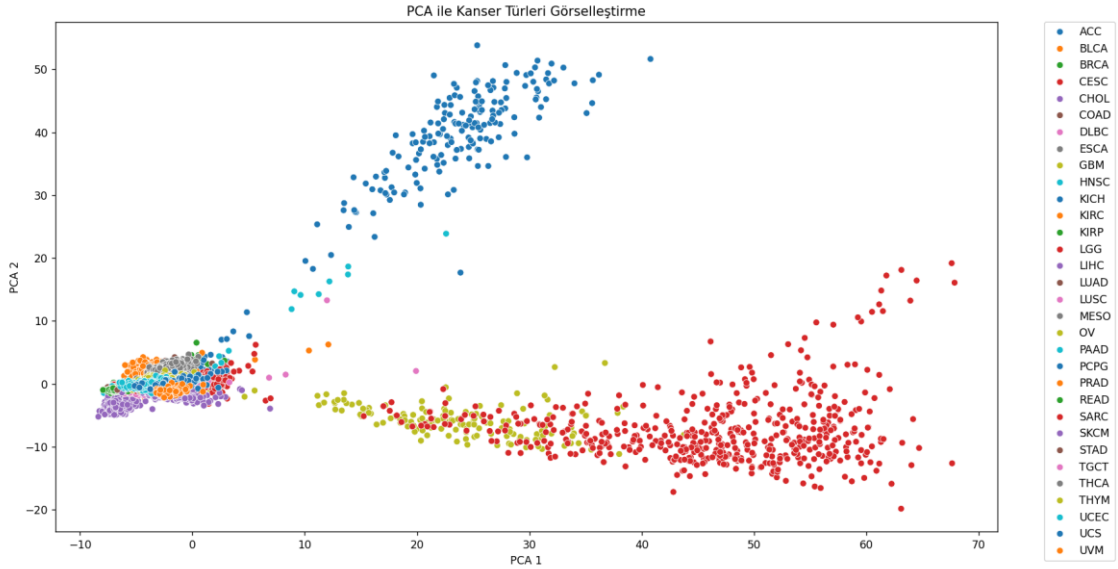

Şekil 2. PCA (Principal Component Analysis) kullanılarak iki boyuta indirgenmiş gen ekspresyon verisinin örnekleri arasındaki dağılımı. Bazı kanser türlerinin PCA düzleminde ayrıştığı gözlemlenmektedir.

3.4. Veri Normalizasyonu

Seçilen genlerin ekspresyon seviyeleri farklı ölçeklerde olabileceği için tüm özellikler Standard Scaler yöntemi ile normalize edildi. Bu işlem, her özelliğin ortalamasını 0 ve standart sapmasını 1 olacak şekilde yeniden ölçeklendirdi. Bu sayede özellikle mesafe tabanlı ve doğrusal modellerin daha sağlıklı çalışması sağlandı.

3.5. Model Eğitimi ve Makine Öğrenimi Yaklaşımları

Kanser türlerinin sınıflandırılmasında farklı makine öğrenimi algoritmalarının performanslarını karşılaştırmak amacıyla dört farklı model eğitildi:

Lojistik Regresyon (Logistic Regression): Doğrusal sınıflandırma yapan ve yorumlanabilirliği yüksek temel model.

Rassal Orman (Random Forest): Karar ağaçları üzerine kurulu ve veri setindeki karmaşık ilişkilere duyarlı güçlü bir topluluk (ensemble) modeli.

Yapay Sinir Ağı (Neural Network - MLPClassifier): Daha karmaşık, katmanlı öğrenme yeteneğine sahip model.

Destek Vektör Makineleri (SVM): Özellikle küçük ve karmaşık veri kümelerinde iyi performans gösterebilen margin tabanlı sınıflandırıcı.

Modellerin eğitimi sırasında veri rastgele %80 eğitim ve %20 test olacak şekilde ayrıldı. Hiperparametre ayarları, temel olarak sklearn kütüphanesinin varsayılan değerleri kullanılarak optimize edilmedi ve modellerin saf kapasiteleri değerlendirildi.

3.6. Model Değerlendirme ve Karşılaştırma

Modellerin genel başarılarını daha güvenilir değerlendirmek amacıyla 5 katlı çapraz doğrulama (5-fold cross validation) uygulandı. Böylece her model için ortalama doğruluk skoru ve skorun standart sapması hesaplandı. Ayrıca her modelin eğitim ve test veri setlerindeki başarımı; accuracy (doğruluk), precision (kesinlik), recall (duyarlılık) ve f1-score metrikleri ile detaylı şekilde raporlandı.

Çapraz doğrulama ve test doğruluğu skorlarına göre:

- En yüksek başarı Logistic Regression modeli tarafından elde edildi.
- Logistic Regression modeli %94.77 çapraz doğrulama doğruluğu ve %94.62 test doğruluğu sağlamıştır.
- Random Forest ve Neural Network modelleri de benzer yüksek doğruluklara ulaşmış, ancak Logistic Regression modeli hem kararlılık hem genel başarım açısından öne çıkmıştır.

```
Model Karşılaştırma Tablosu:
                  Model  CV Score (Mean)  CV Score (Std)  Train Score  Test Score
Logistic Regression           0.947722        0.002984     0.997225    0.946262
      Random Forest           0.945385        0.005941     1.000000    0.942757
     Neural Network           0.947137        0.003943     1.000000    0.941005
                SVM           0.933121        0.006069     0.952541    0.929322

En iyi model: Logistic Regression
```

Şekil 3. Dört farklı makine öğrenimi modelinin çapraz doğrulama, eğitim ve test seti doğrulukları karşılaştırılmıştır. Logistic Regression modeli en yüksek genel doğruluk ve dengeyi sağlamıştır.

4. Sonuçlar

Bu çalışmada, TCGA Pan-Cancer RNA-Seq verisi kullanılarak çoklu kanser türlerinin sınıflandırılması amacıyla makine öğrenimi tabanlı bir modelleme süreci gerçekleştirilmiştir. Çalışma boyunca toplamda 20.533 gen ifadesinden oluşan yüksek boyutlu verinin önce varyans analizi, ardından da SelectKBest yöntemi ile boyutu düşürülmüş ve nihayetinde 500 özelliğe indirgenmiştir. Bu boyut indirgeme süreci, modelin hem hesaplama verimliliğini artırmış hem de aşırı öğrenme (overfitting) riskini azaltmıştır.

Uygulanan dört farklı makine öğrenimi algoritması arasında Logistic Regression modeli, gerek çapraz doğrulama skoru (%94.77), gerekse test setindeki doğruluğu (%94.62) ile en başarılı sonuçları vermiştir. Model, yüksek doğruluk oranının yanı sıra sınıf dengesi açısından da güçlü bir performans sergilemiştir.

Modelin başarısını detaylı şekilde değerlendirmek amacıyla oluşturulan karmaşıklık matrisi (confusion matrix) incelendiğinde; özellikle örnek sayısı yüksek kanser türlerinde (örneğin BRCA, PRAD, HNSC) doğru sınıflandırma oranlarının oldukça yüksek olduğu görülmektedir. Bununla

birlikte, sınıf sayısı az ve örnek dağılımı dengesiz olan bazı kanser türlerinde (örneğin OV, STAD, SARC) sınıflandırma doğruluğunda kısmi düşüşler yaşanmıştır. Bu durum, sınıflar arası dengesizliğin model başarımı üzerinde belirleyici bir etkiye sahip olduğunu göstermektedir.

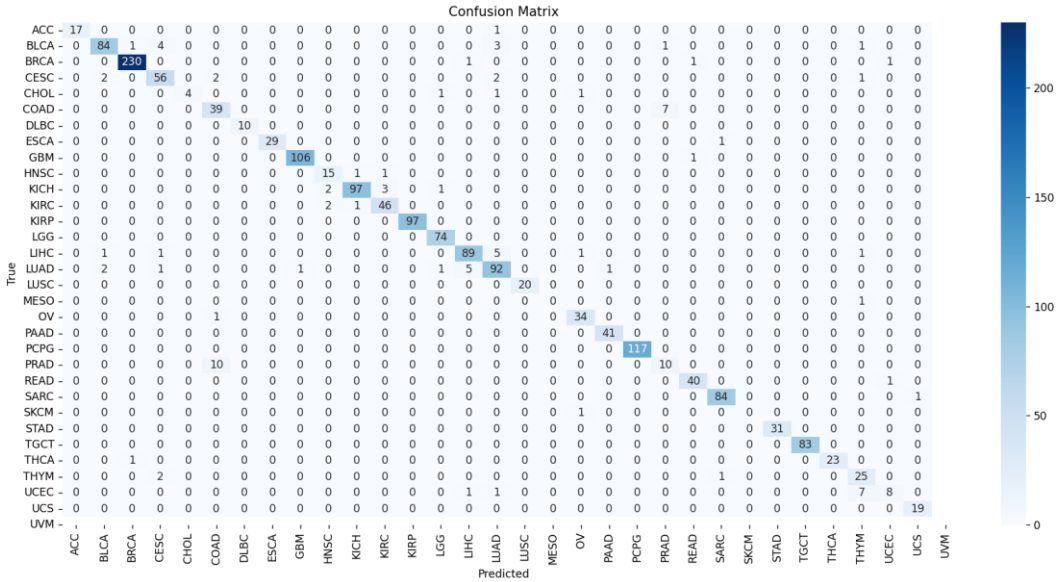

Şekil 3. Logistic Regression modelinin test seti üzerinde elde ettiği karmaşıklık matrisi. Özellikle örnek sayısı yüksek kanser türlerinde yüksek sınıflandırma başarısı görülmektedir.

Modelin sınıf bazında değerlendirmesi incelendiğinde, özellikle örnek sayısı yüksek olan kanser türlerinde (örneğin BRCA, HNSC, PRAD) oldukça yüksek f1-score değerlerine ulaşıldığı görülmüştür. Öte yandan, örnek sayısı çok düşük olan bazı nadir kanser türlerinde (örneğin OV, STAD, SARC) modelin başarımı görece daha düşüktür. Bu durum, sınıflar arasındaki dengesiz veri dağılımının sınıflandırma performansını etkileyebileceğini göstermektedir.

```
Classification Report:
              precision    recall  f1-score   support

         ACC       1.00      0.94      0.97        18
        BLCA       0.94      0.89      0.92        94
        BRCA       0.99      0.99      0.99       233
        CESC       0.88      0.89      0.88        63
        CHOL       1.00      0.57      0.73         7
        COAD       0.75      0.85      0.80        46
        DLBC       1.00      1.00      1.00        10
         GBM       1.00      0.97      0.98        30
        HNSC       0.99      0.99      0.99       107
        KICH       0.79      0.88      0.83        17
        KIRC       0.98      0.94      0.96       103
        KIRP       0.92      0.94      0.93        49
         LGG       1.00      1.00      1.00        97
        LIHC       0.96      1.00      0.98        74
        LUAD       0.93      0.91      0.92        98
        LUSC       0.88      0.89      0.88       103
        MESO       1.00      1.00      1.00        20
          OV       0.00      0.00      0.00         1
        PAAD       0.92      0.97      0.94        35
        PCPG       0.98      1.00      0.99        41
        PRAD       1.00      1.00      1.00       117
        READ       0.56      0.50      0.53        20
        SARC       0.95      0.98      0.96        41
        SKCM       0.98      0.99      0.98        85
        STAD       0.00      0.00      0.00         1
        TGCT       1.00      1.00      1.00        31
        THCA       1.00      1.00      1.00        83
        THYM       1.00      0.96      0.98        24
        UCEC       0.69      0.89      0.78        28
         UCS       0.80      0.47      0.59        17
         UVM       0.95      1.00      0.97        19

    accuracy                           0.95      1712
   macro avg       0.87      0.85      0.85      1712
weighted avg       0.95      0.95      0.95      1712

Test Accuracy: 0.9462616822429907
```

Şekil 4. Logistic Regression modelinin test seti üzerinde her bir kanser türü için elde ettiği precision, recall ve f1-score değerleri.

Ayrıca, Logistic Regression modelinin ağırlık katsayıları (feature coefficients) üzerinden yapılan analizde, sınıflandırmaya en fazla katkı sağlayan ilk 20 gen belirlenmiştir. Bu genler, sınıflandırma sürecinde biyolojik anlamda potansiyel biyobelirteç adayları olarak ön plana çıkmaktadır. Özellikle bazı genlerin, kanser türleri arasındaki farklı gen ekspresyon paternlerini güçlü şekilde yansıttığı gözlemlenmiştir. Bu bulgular, hem biyoinformatik araştırmalar hem de klinik uygulamalar açısından önemli bir biyolojik içgörü sunmaktadır.

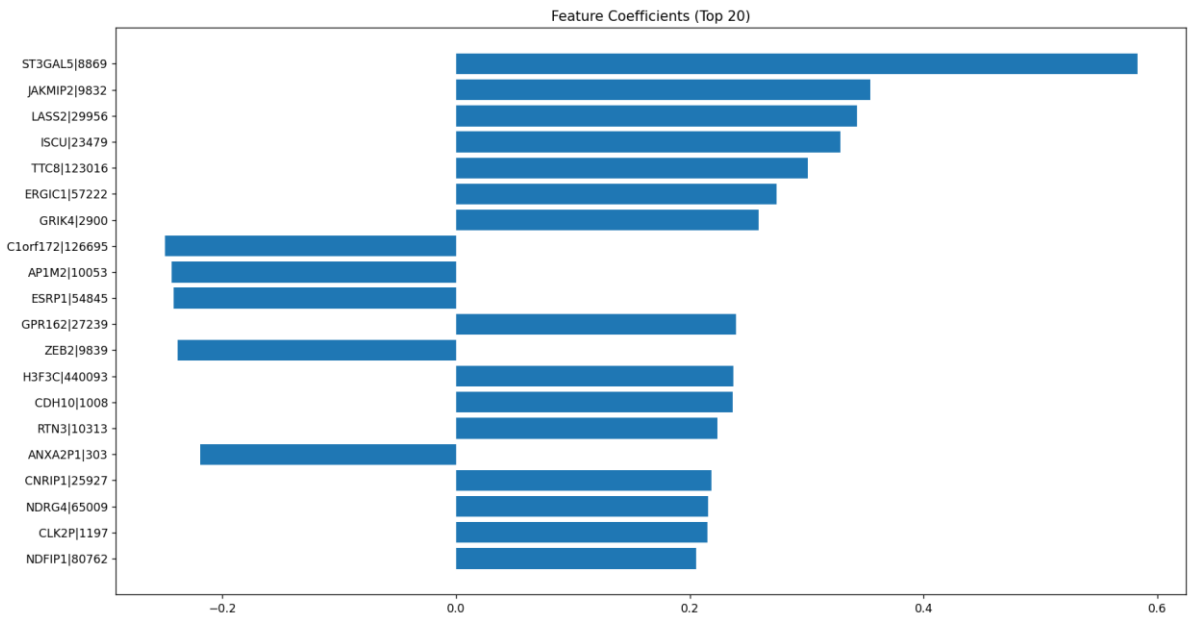

Şekil 5. Logistic Regression modeli tarafından en yüksek ağırlığa sahip ilk 20 gen. Bu genler, sınıflandırma kararına en fazla katkıda bulunan potansiyel biyobelirteç adaylarıdır.

Genel anlamda, elde edilen yüksek doğruluk oranları, oluşturulan dengeli sınıflandırma performansı ve öne çıkan biyobelirteç adayları ışığında; gen ekspresyon profillerine dayalı makine öğrenimi modellerinin çoklu kanser sınıflandırmasında etkili ve uygulanabilir olduğu sonucuna ulaşılmıştır.

Gelecekte yapılacak çalışmalarda, sınıf dengesizliği probleminin SMOTE gibi veri dengeleme teknikleriyle ele alınması, hiperparametre optimizasyonlarının genişletilmesi ve farklı algoritmalarla melez modellerin oluşturulması ile performansın daha da artırılabileceği düşünülmektedir. Ayrıca, genomik, klinik ve görüntüleme verilerinin entegre edilmesiyle daha kapsamlı ve hassas teşhis sistemlerinin geliştirilmesi de önemli bir potansiyel araştırma alanı olarak ön plana çıkmaktadır.

KAYNAKÇA

Chaudhary, K., Poirion, O. B., Lu, L., & Garmire, L. X. (2018). Deep learning–based multi-omics integration robustly predicts survival in liver cancer. *Clinical cancer research*, *24*(6), 1248-1259.

Chen, T., & Guestrin, C. (2016, August). Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining* (pp. 785-794).

Chandrashekar, G., & Sahin, F. (2014). A survey on feature selection methods. *Computers & electrical engineering*, *40*(1), 16-28.

Guyon, I., & Elisseeff, A. (2003). An introduction to variable and feature selection. *Journal of machine learning research*, *3*(Mar), 1157-1182.

Kourou, K., Exarchos, T. P., Exarchos, K. P., Karamouzis, M. V., & Fotiadis, D. I. (2015). Machine learning applications in cancer prognosis and prediction. *Computational and structural biotechnology journal*, *13*, 8-17.

Nitta, Y., Borders, M., & Ludwig, S. A. (2021, December). Analysis of Gene Expression Cancer Data Set: Classification of TCGA Pan-cancer HiSeq Data. In *2021 IEEE International Conference on Big Data (Big Data)* (pp. 4745-4752). IEEE.

Libbrecht, M. W., & Noble, W. S. (2015). Machine learning applications in genetics and genomics. *Nature Reviews Genetics*, *16*(6), 321-332.

Liu, J., Lichtenberg, T., Hoadley, K. A., Poisson, L. M., Lazar, A. J., Cherniack, A. D., ... & Cope, L. (2018). An integrated TCGA pan-cancer clinical data resource to drive high-quality survival outcome analytics. *Cell*, *173*(2), 400-416.

Siegel, R. L., Miller, K. D., & Jemal, A. (2018). Cancer statistics, 2018. *CA: a cancer journal for clinicians*, *68*(1), 7-30.

Wang, Z., Gerstein, M., & Snyder, M. (2009). RNA-Seq: a revolutionary tool for transcriptomics. *Nature reviews genetics*, *10*(1), 57-63.

Weinstein, J. N., Collisson, E. A., Mills, G. B., Shaw, K. R., Ozenberger, B. A., Ellrott, K., ... & Stuart, J. M. (2013). The cancer genome atlas pan-cancer analysis project. *Nature genetics*, *45*(10), 1113-1120.

Alharbi, F., & Vakanski, A. (2023). Machine learning methods for cancer classification using gene expression data: A review. *Bioengineering*, *10*(2), 173.